

Séries temporelles

Patrick Waelbroeck

Telecom Paris

March 6, 2020

On utilise la base de données `intdef.raw`.

```
df = pd.read_csv('intdef.raw', delim_whitespace=True, header=None)
```

Exercice 1

Représenter graphiquement les séries `i3`, `inf` et `def` en fonction de l'année. Discuter la stationnarité.

```
year=df[0]
i3=df[1]
plt.plot(year,i3)
inf=df[2]
plt.plot(year,inf)
deficit=df[5]
plt.plot(year,deficit)
```



Exercice 2

Estimer le modèle $y(t) = i3(t)$ en fonction d'une constante, de $def(t-1)$ et $inf(t-1)$

Exercice à faire en deux étapes. Première étape, construire $def(t-1)$ et $inf(t-1)$. Pour calculer les lags, on peut utiliser la fonction `shift(-1)` de `panda`, mais je ne le recommande pas, car on ne traite pas les valeurs manquantes de manière explicite. Deuxième étape : construire $y(t) = i3(t)$ et $X(t)$.

Attention aux indices et aux dimensions des array.

Remarque : on perd la première observation (normal, puisqu'on utilise une valeur laggée).

```
n=len(inf)
inf_1=inf[0:n-1]
def_1=deficit[0:n-1]
y=i3[1:n]
const=np.ones(n-1)
X=np.column_stack((const, inf_1,def_1))
```

```
model=sm.OLS(y,X)
results = model.fit()
print(results.summary())
```

Attention le nombre d'observation est 55.

Remarque : il s'agit d'une équation d'un système Vector Auto Regression (VAR) en supposant que les valeurs passées de $i3$ n'influence pas sa valeur actuelle. On peut tester cette hypothèse (voir plus loin).

Dep. Variable:	1	R-squared:	0.594			
Model:	OLS	Adj. R-squared:	0.578			
Method:	Least Squares	F-statistic:	38.03			
Date:	Fri, 06 Mar 2020	Prob (F-statistic):	6.67e-11			
Time:	09:48:57	Log-Likelihood:	-110.27			
No. Observations:	55	AIC:	226.5			
Df Residuals:	52	BIC:	232.6			
Df Model:	2					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	1.8930	0.435	4.356	0.000	1.021	2.765
x1	0.5672	0.083	6.865	0.000	0.401	0.733
x2	0.5521	0.120	4.616	0.000	0.312	0.792
=====						
Omnibus:	2.640	Durbin-Watson:	0.812			
Prob(Omnibus):	0.267	Jarque-Bera (JB):	2.043			
Skew:	-0.317	Prob(JB):	0.360			
Kurtosis:	2.300	Cond. No.	9.27			
=====						

Exercice 3

Tester l'autocorrélation des erreurs en testant l'hypothèse

$$H_0 : \rho = 0$$

dans l'équation $u(t) = \rho u(t-1) + \nu$

ON récupère les erreurs on on construit la variable $u(t-1)$.

Attention : on perd à nouveau une observation !

```
u=results.resid
n=len(u)
u_1=u[0:n-1]
const=np.ones(n-1)
X=np.column_stack((const, u_1))
X=X[:,1]
y=u[1:n]
model=sm.OLS(y,X)
results1 = model.fit()
print(results1.summary())
```

$p=0.0$. On rejette l'hypothèse H_0 à 1%.

OLS Regression Results

Dep. Variable:	y	R-squared (uncentered):	0.332
Model:	OLS	Adj. R-squared (uncentered):	0.319
Method:	Least Squares	F-statistic:	26.32
Date:	Fri, 06 Mar 2020	Prob (F-statistic):	4.20e-06
Time:	10:34:49	Log-Likelihood:	-96.613
No. Observations:	54	AIC:	195.2
Df Residuals:	53	BIC:	197.2
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
x1	0.5738	0.112	5.130	0.000	0.349	0.798

Omnibus:	2.025	Durbin-Watson:	1.489
Prob(Omnibus):	0.363	Jarque-Bera (JB):	1.963
Skew:	-0.405	Prob(JB):	0.375
Kurtosis:	2.535	Cond. No.	1.00

Exercice 4

Utiliser la transformation $y(t) - \rho y(t-1)$ et $X_k(t) - \rho X_k(t-1)$

```
rho=results1.params[0]
```

Attention aux indices sous Python.

Exercice 5

Introduire $\text{inf}(t-2)$ et $\text{def}(t-2)$ dans le modèle de l'exercice 2. Représentez les délais distribués

```
n=len(i3)
y=i3[2:n]
inf_1=inf[1:n-1]
inf_2=inf[0:n-2]
def_1=deficit[1:n-1]
def_2=deficit[0:n-2]
const=np.ones(n-2)
X=np.column_stack((const, inf_1,inf_2,def_1,def_2))

model=sm.OLS(y,X)
results = model.fit()
print(results.summary())

d_inf=(results.params[1], results.params[2])
x=(1,2)
plt.bar(x,d_inf)
```

Exercice 6

Test l'hypothèse de causalité de Granger de l'effet de l'inflation sur $i3$.

Résultat pour la statistique de Fisher et la p-value :

$F=25.069$

On rejette l'hypothèse $H_0(p < 0.01)$.